Vector DB 선택하기

Vector DB 는 써야되긴 하겠으나, 어떤 벡터 DB 가 괜찮은지 몰라 몇 가지 벡터 데이터베이스에 대한 특징을 정리해보았다. 이 중 적합한 것을 찾아 사용해보자

	Pinecone	Weaviate	Milvus	Qdrant	Chroma	Elasticsearch	PGvector
Is open source	❌	✅	✅	✅	✅	❌	✅
Self-host	❌	✅	✅	✅	✅	✅	✅
Cloud management	✅	✅	✅	✅	❌	✅	(✓)
Purpose-built for Vectors	✅	✅	✅	✅	✅	❌	❌
Developer experience	👍👍👍	👍👍	👍👍	👍👍	👍👍	👍	👍
Community	Community page & events	8k☆ github, 4k slack	23k☆ github, 4k slack	13k☆ github, 3k discord	9k☆ github, 6k discord	23k slack	6k☆ github
Queries per second (using text nytimes-256-angular)	150 *for p2, but more pods can be added	791	2406	326	?	700-100 *from various reports	141
Latency, ms (Recall/Percentile 95 (millis), nytimes-256-angular)	1 *batched search, 0.99 recall, 200k SBERT	2	1	4	?	?	8
Supported index types	?	HNSW	Multiple (11 total)	HNSW	HNSW	HNSW	HNSW/IVFFlat
Hybrid Search (i.e. scalar filtering)	✅	✅	✅	✅	✅	✅	✅
Disk index support	✅	✅	✅	✅	✅	❌	✅
Role-based access control	✅	❌	✅	❌	❌	✅	❌
Dynamic segment placement vs. static data sharding	?	Static sharding	Dynamic segment placement	Static sharding	Dynamic segment placement	Static sharding	-
Free hosted tier	✅	✅	✅	(free self-hosted)	(free self-hosted)	(free self-hosted)	(varies)
Pricing (50k vectors @1536)	$70	fr. $25	fr. $65	est. $9	Varies	$95	Varies

* Self-Host: 데이터베이스가 타사 클라우드 서비스에 의존하지 않고 사용자의 자체 인프라에 호스팅될 수 있는지 여부 지정
** Latency: 요청을 시작하고 응답을 받기까지의 지연 시간(밀리초)
*** Disk index support: ChatGPT 데이터베이스가 디스크에 인덱스를 저장하는 것을 지원하는지 여부. 메모리에 맞지 않는 대규모 데이터셋을 처리하는 데 필수적

Case 1. Open-Source and hosted cloud
- Weviate, Milvus, and Chroma 를 고려하는 것이 좋다.

Case 2. Performance
- 성능을 우선시한다면, 초당 쿼리 수에 대한 순수 성능 측면에서 Milvus 가 선두를 차지하고, 그 뒤를 바짝 쫓는 Weviate 와 Qdrant 를 고려하는 것이 좋다. 지연 시간 측면에서 Pinecone 과 Milvus 모두 인상적인 2ms 이하의 결과를 제공하며, Pinecone 에 여러 개의 포드를 추가하면 훨씬 더 높은 QPS 를 달성할 수 있다.

Case 3. Community Strength - 커뮤니티 크기를 우선시한다면, Milvus 는 가장 큰 커뮤니티를 자랑하며, 그 뒤를 바짝 쫓는 Weviate 와 Elasticsearch 를 고려하는 것이 좋다.

Case 4. Scalability, advanced features and security - 확장성 및 고급 기능과 보안을 우선시한다면, 많은 기업 애플리케이션에 중요한 기능인 역할 기반 액세스 제어를 제공하는 Pinecone, Milvus, ElasticSearch 를 고려하는 것이 좋고 다양한 인덱스 유형이 필요한 경우 11 가지 다른 유형의 인덱스를 제공하는 Milvus 를 사용하는 것이 좋다. 확장성 측면에서, Milvus 와 Chroma 는 동적 세그먼트 배치를 제공하여 지속적으로 변화하는 데이터세트에 적합하다.

Case 5. Price
- 스타트업이나 예산이 제한된 프로젝트의 경우, 50k 벡터에 대한 Qdrant 의 약 $9 가격은 매우 경쟁력 있다. 반면, 높은 성능을 요구하는 대규모 프로젝트의 경우 Pinecone 과 Milvus 는 경쟁력 있는 가격 체계를 제공한다.